# Joao Otavio Moraes RM573227_fase1_cap2.

# Relato de Experimento: Treinamento de Modelo no Teachable Machine

Desafios Iniciais e Problemas de Contexto

Iniciei o teste com dois utensílios de cozinha: a espátula e o fouet. Acreditei que, apesar de possuírem cores semelhantes, o sistema identificaria facilmente a diferença de formatos, especialmente devido aos arames vazados do fouet.

o primeiro problema encontrado foi a dificuldade do modelo em diferenciar o objeto do plano de fundo. Por exemplo, o reflexo no espelho posicionado atrás de mim era frequentemente identificado como a espátula. Da mesma forma, quando a câmera era desligada e o vídeo tornava-se preto, o sistema também acusava a presença da espátula, provavelmente pela predominância da cor sólida preta. Para expandir o teste, adicionei um terceiro objeto: a pinça, que introduziu um novo formato e uma diferenciação de cor mais nítida.

Volume de Dados e Viés

Inicialmente, utilizei por volta de 275 fotos para cada classe quantidade que julguei adequada no início. No entanto, o modelo apresentou dificuldades básicas, como não reconhecer o objeto ao trocar de mão, demonstrando uma confusão óbvia entre o que seria o item em si e o que seria parte do meu corpo.

Ao tentar corrigir esse defeito, aumentei a base de dados de forma desequilibrada, passando para mais de 800 fotos para a espátula e 600 para a pinça. O resultado foi um modelo extremamente enviesado: o sistema praticamente parou de reconhecer o fouet (que ainda continha apenas as 275 fotos originais) e passou a indicar a espátula em quase todos os casos. O problema se agravou quando alterei o número de épocas para 500 (um aumento de 10x); o modelo "viciou" na classe com maior densidade de dados, tornando-se pouco funcional.

A Importância do Ambiente

Um aprendizado crucial foi perceber que o modelo não foca apenas no objeto, mas em todo o quadro (frame). Dediquei muita importância aos ângulos dos objetos para que fossem lidos em todas as posições, mas isso acabou sendo contraproducente. Notei que a composição do ambiente ao redor confere uma credibilidade muito maior ao modelo.

Como girei a pinça por 600 fotos sem aparecer no enquadramento, o sistema passou a associar a minha presença às outras classes (nas quais eu estava presente durante a captura). Ou seja, negligenciei o ambiente à volta; detalhes como estar ou não de jaqueta ou a aparição do espelho influenciaram mais a acurácia do que o objeto propriamente dito.

Ajustes e Resultados Finais

Diante desses erros, reiniciei o processo do zero. Montei uma base equilibrada de 800 fotos por classe,

garantindo que eu aparecesse em todas as imagens, trocando de mãos e entrando/saindo do quadro para ajudar o modelo a diferenciar o objeto da minha imagem. Para testar a adaptação inicial, reduzi o número de épocas para 10, um numero relativamente baixo, notei que apesar de reconhecer com razoável precisão, o sistema ficava confuso fácil com diferentes poses, assim então, subi para 100 e assim o mantive.

Após essas novas capturas, a acurácia melhorou significativamente. Além de reconhecer os objetos com maior precisão, o sistema agora demonstra incerteza ao ser apresentado a objetos não treinados, como um controle de videogame, o que é um comportamento esperado de um modelo bem ajustado. Em testes com dois objetos simultâneos, o sistema tende a acusar a pinça; acredito que o aspecto metálico e a cor facilitem esse discernimento, sobrepondo-se a detalhes como espessura ou formato.

## Conclusão

Concluo que os pequenos detalhes que eu julgava críticos — como a semelhança entre os cabos do fouet e da espátula — não chegaram a ser os fatores de maior relevância. Em contrapartida, o ambiente filmado, minhas mãos, rosto e roupas tiveram um impacto significativo na resposta do sistema.

Uma abordagem mais abrangente, que deu foco além dos ângulos e priorizou os arredores e uma visão "macro" do aprendizado, foi o que trouxe resultados satisfatórios. Atualmente, o modelo possui uma eficácia alta, em torno de 80%. Para os próximos passos, o ideal seria introduzir uma diversidade maior de ambientes e pessoas. Por fim, ensinar ao sistema o que não são os utensílios provou ser a melhor forma de identificar o que eles realmente são.

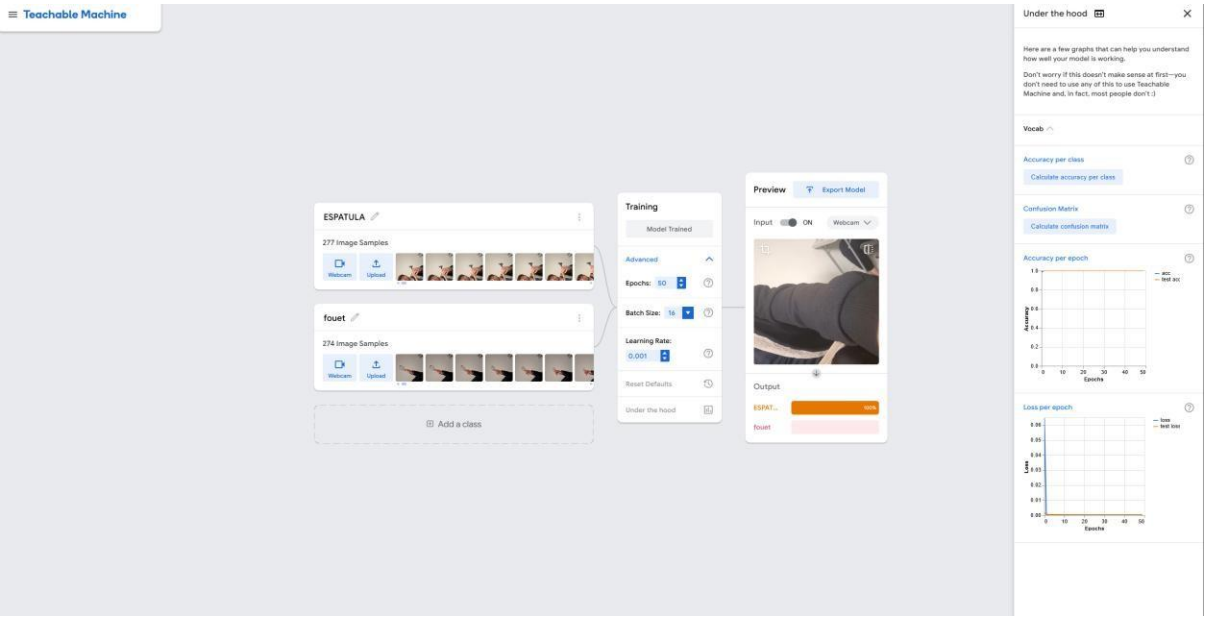

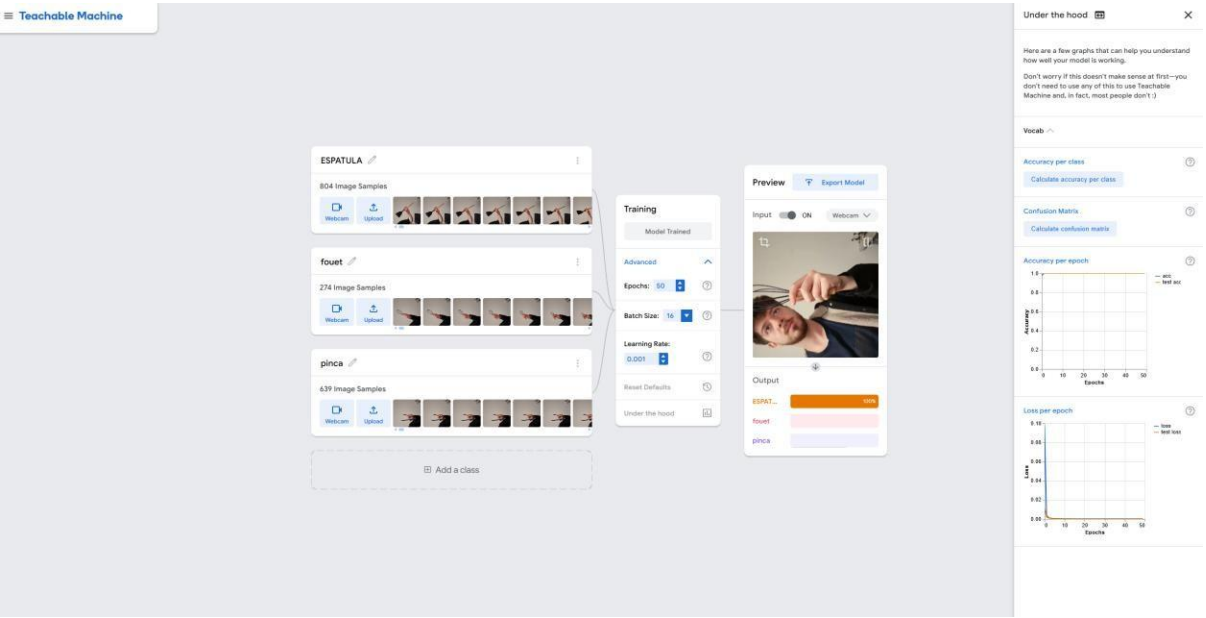
Teachable Machine
ESPATULA
804 Image Samples
Webcam
Upload
fouet
274 Image Samples
pinca
639 Image Samples
Add a class
Training
Model Trained
Advanced
Epochs: 50
Batch Size: 16
Learning Rate:
0.001
Reset Defaults
Under the hood
Preview
Export Model
Input
ON
Webcam
Output
ESPAT...
100%
fouet
pinca
Under the hood
Here are a few graphs that can help you understand how well your model is working.
Don't worry if this doesn't make sense at first—you don't need to use any of this to use Teachable Machine and, in fact, most people don't :)
Vocab
Accuracy per class
Calculate accuracy per class
Confusion Matrix
Calculate confusion matrix
Accuracy per epoch
acc
test acc
Accuracy
Epoche
Loss per epoch
loss
test loss
Loss
Epoche

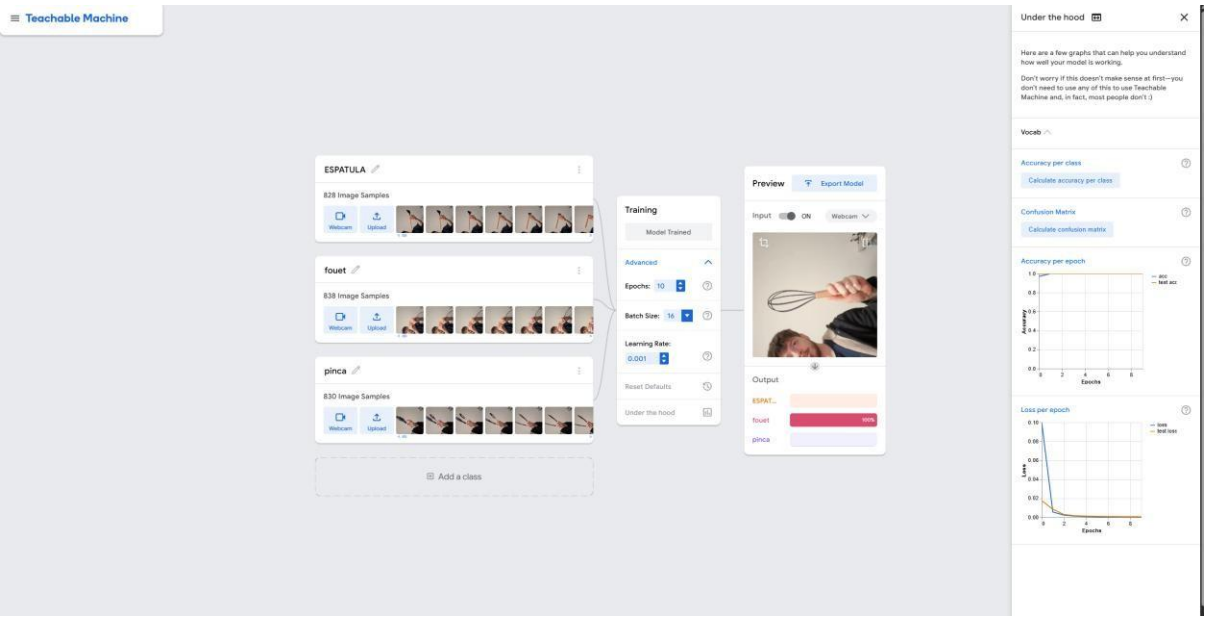
Teachable Machine
ESPATULA
828 Image Samples
Webcam
Upload
fouet
838 Image Samples
pinca
830 Image Samples
Add a class
Training
Model Trained
Advanced
Epochs: 10
Batch Size: 16
Learning Rate:
0.001
Reset Defaults
Under the hood
Preview
Export Model
Input
ON
Webcam
Output
ESPAT...
fouet
100%
pinca
Under the hood
Here are a few graphs that can help you understand how well your model is working.
Don't worry if this doesn't make sense at first—you don't need to use any of this to use Teachable Machine and, in fact, most people don't :)
Vocab
Accuracy per class
Calculate accuracy per class
Confusion Matrix
Calculate confusion matrix
Accuracy per epoch
acc
test acc
Accuracy
Epoche
Loss per epoch
loss
test loss
Loss
Epoche

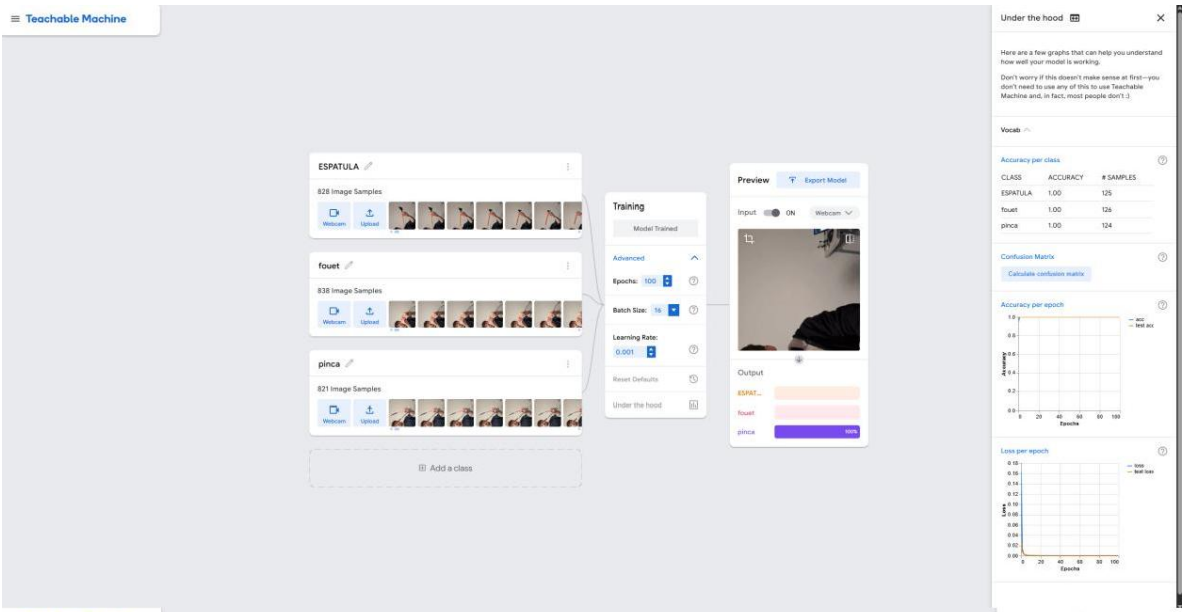
Teachable Machine
ESPATULA
828 Image Samples
Webcam
Upload
fouet
838 Image Samples
pinca
821 Image Samples
Add a class
Training
Model Trained
Advanced
Epochs: 100
Batch Size: 16
Learning Rate:
0.001
Reset Defaults
Under the hood
Preview
Export Model
Input
ON
Webcam
Output
ESPAT...
fouet
pinca
100%
Under the hood
Here are a few graphs that can help you understand how well your model is working.
Don't worry if this doesn't make sense at first—you don't need to use any of this to use Teachable Machine and, in fact, most people don't :)
Vocab
Accuracy per class
CLASS
ACCURACY
# SAMPLES
ESPATULA
1.00
125
fouet
1.00
126
pinca
1.00
124
Confusion Matrix
Calculate confusion matrix
Accuracy per epoch
acc
test acc
Accuracy
Epoche
Loss per epoch
loss
test loss
Loss
Epoche

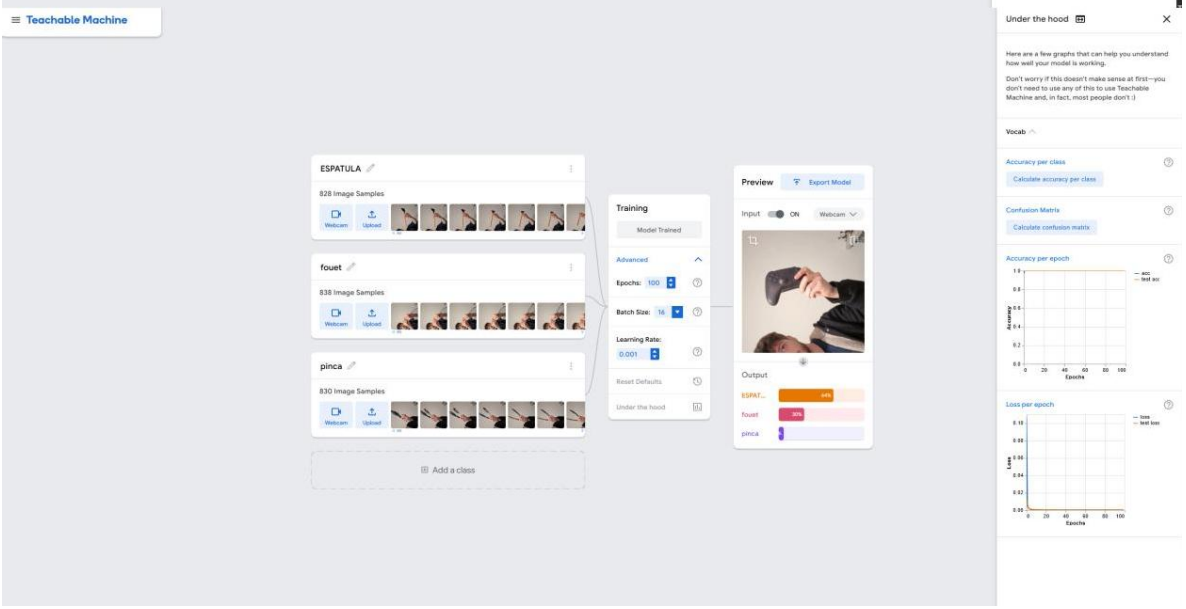
Teachable Machine
ESPATULA
828 Image Samples
Webcam
Upload
fouet
838 Image Samples
pinca
830 Image Samples
Add a class
Training
Model Trained
Advanced
Epochs: 100
Batch Size: 16
Learning Rate:
0.001
Reset Defaults
Under the hood
Preview
Export Model
Input
ON
Webcam
Output
ESPAT...
64%
fouet
32%
pinca
Under the hood
Here are a few graphs that can help you understand how well your model is working.
Don't worry if this doesn't make sense at first—you don't need to use any of this to use Teachable Machine and, in fact, most people don't :)
Vocab
Accuracy per class
Calculate accuracy per class
Confusion Matrix
Calculate confusion matrix
Accuracy per epoch
acc
test acc
Accuracy
Epoche
Loss per epoch
loss
test loss
Loss
Epoche